

各国经济对人工智能依赖度的文本分析

基于 Wikipedia 经济词条的词向量方法

Siyao Zheng*

July 4, 2026

Abstract

本文利用 30 国 Wikipedia 「Economy of X」词条的导言文本，通过 Sentence-BERT 词向量方法构建了「经济对 AI 依赖度」指标。以 23 个 AI 锚定短语的均值向量为 AI 概念向量，计算 588 条句子的余弦相似度，按国家聚合排名。中国 (0.258)、南非 (0.247)、印度 (0.237) 位居前三；沙特阿拉伯 (0.105) 垫底。Top-5 组的高相似度句子占比达 21.2%，是 Bottom-5 组 (1.2%) 的 17 倍。最终输出包含四维度分析、例句验证和可复现 pipeline 的全套教学演示材料。

1 引言

「哪些国家的经济更依赖 AI？」传统回答依赖专利数量或 R&D 支出占比等结构化指标。本文尝试一种互补思路：从各国经济描述的语言特征中推断 AI 相关度。如果一国经济文本中频繁出现与 AI 语义相近的表述，我们推断其经济叙事更深度地嵌入了 AI 和相关数字技术。

具体地，从 Wikipedia 抓取 30 国「Economy of X」词条导言 (introductory extract)，用 Sentence-BERT 对所有句子进行语义编码，构建 AI 概念向量，计算余弦相似度，按国家聚合。全文所有步骤由 Python pipeline 自动化，数据、脚本、输出均可在项目目录中复现。

2 数据与预处理

2.1 语料来源

Wikipedia API 抓取 30 国英文词条导言，覆盖各大洲和不同收入水平。总计 74,524 字符、11,606 词、平均 387 词/文档。语料很小但适合课堂演示。

2.2 预处理流程

1. NLTK `sent_tokenize` 分句；
2. NLTK `word_tokenize` 分词并小写；
3. 去除英文停用词及额外低信息词 (also, however 等)；
4. WordNetLemmatizer 词形还原；
5. 过滤：去纯标点/纯数字 token、长度 ≤ 2 token、token 数 < 3 的句子。

最终得到 588 条有效句子，6,437 个 token，1,735 个唯一词型。

*计算社会科学；上海交通大学

3 方法

3.1 AI 锚定短语与概念向量

设计 23 个 AI 锚定短语，覆盖四个维度（表 1）。使用 Sentence-BERT all-MiniLM-L6-v2 (384 维) 编码所有锚定短语，取均值后归一化作为 AI 概念向量 $\mathbf{v}_{\text{AI}}$ 。

Table 1: AI 锚定短语

维度 (7/5/4/7 条)	锚定短语
AI 技术核心	artificial intelligence and machine learning technologies
	deep learning neural networks and AI research
	robotics and intelligent automation systems
	advanced algorithms and data-driven decision making
	automated manufacturing and smart factories
	AI-powered software and digital platforms
经济结构转型	semiconductor chips and AI computing hardware
	digital economy and technology-driven growth
	innovation in high-tech industries
	knowledge economy and research development
	technology exports and intellectual property
劳动力与技能	digital transformation of traditional industries
	highly skilled technology workforce
	STEM education and technical training
	automation replacing routine jobs
	digital skills and computer literacy
数字基础设施	internet connectivity and digital infrastructure
	cloud computing and data centers
	broadband access and mobile technology
	e-government and digital public services
	fintech and digital financial services
	startup ecosystem and venture capital in tech
	investment in R&D

3.2 余弦相似度与国家聚合

对 588 条句子逐一编码得到 $\mathbf{s}_i$ ，计算余弦相似度 $\text{Sim}_i = \frac{\mathbf{s}_i \cdot \mathbf{v}_{\text{AI}}}{\|\mathbf{s}_i\| \|\mathbf{v}_{\text{AI}}\|}$ 。按国家 c 取均值： $\text{AI-Dep}_c = \frac{1}{N_c} \sum_{i \in c} \text{Sim}_i$ ，同时报告中位数、最大值、标准差、P75、P90 及高相似度句子占比 ($\text{Sim}_i > 0.3$)。

4 结果

4.1 整体分布

588 条句子相似度均值 0.192，中位数 0.188，标准差 0.086，范围 $[-0.031, 0.546]$ 。9.4% 的句子相似度 > 0.3 ，整体呈轻微右偏。

4.2 各维度 AI 概念向量相关性检验

为验证 AI 概念向量的内部一致性，计算四个维度锚定向量两两之间的余弦相似度：

- AI 核心-经济转型: 0.649
- AI 核心-劳动力: 0.529
- AI 核心-基础设施: 0.630
- 经济转型-劳动力: 0.524
- 经济转型-基础设施: 0.633
- 劳动力-基础设施: 0.538

各维度间相关系数均在 0.52–0.65 之间，中等偏强相关，说明四个维度共享一个更高阶的「技术-数字经济」语义空间，合成为一个 AI 概念向量是合理的。

4.3 国家排名

表 2 报告全部 30 国排名。Top-5 是中国、南非、印度、印度尼西亚、韩国；Bottom-5 是沙特阿拉伯、智利、俄罗斯、德国、瑞士。

Table 2: 30 国 AI 依赖度完整排名

排名	国家		Mean	Max	High%
1	China	中国	0.258	0.546	25.0%
2	South Africa	南非	0.247	0.408	28.6%
3	India	印度	0.237	0.429	15.4%
4	Indonesia	印度尼西亚	0.231	0.375	23.1%
5	South Korea	韩国	0.229	0.454	18.2%
6	United States	美国	0.219	0.407	17.9%
7	United Kingdom	英国	0.218	0.433	7.7%
8	Turkey	土耳其	0.213	0.460	12.5%
9	Japan	日本	0.211	0.323	9.5%
10	Singapore	新加坡	0.211	0.266	0.0%
11	Vietnam	越南	0.210	0.311	7.7%
12	Egypt	埃及	0.203	0.280	0.0%
13	Ethiopia	埃塞俄比亚	0.198	0.369	12.5%
14	Brazil	巴西	0.194	0.457	4.5%
15	France	法国	0.191	0.333	4.5%
16	Nigeria	尼日利亚	0.189	0.326	8.3%
17	Bangladesh	孟加拉国	0.188	0.337	4.3%
18	Thailand	泰国	0.188	0.522	5.3%
19	Italy	意大利	0.187	0.355	13.3%
20	Poland	波兰	0.174	0.351	5.9%
21	Australia	澳大利亚	0.169	0.293	0.0%
22	Mexico	墨西哥	0.167	0.371	12.5%
23	Canada	加拿大	0.165	0.331	8.8%
24	Argentina	阿根廷	0.154	0.237	0.0%
25	Netherlands	荷兰	0.153	0.413	7.7%
26	Switzerland	瑞士	0.152	0.227	0.0%
27	Germany	德国	0.149	0.334	3.4%
28	Russia	俄罗斯	0.147	0.279	0.0%
29	Chile	智利	0.141	0.280	0.0%
30	Saudi Arabia	沙特阿拉伯	0.105	0.244	0.0%

4.4 分组箱线图

我们将 30 国按排名分为三组：Top-5、Middle (Ethiopia–Thailand)、Bottom-5，各组的句子级相似度分布如表 3 所示。

Table 3: 三组句级相似度分布对比

组别	句数	均值	Q1	中位数	Q3	>0.3 占比
Top-5	99	0.241	0.184	0.228	0.284	21.2%
Middle	122	0.192	0.123	0.192	0.241	6.6%
Bottom-5	81	0.142	0.091	0.137	0.193	1.2%

Top-5 组均值 (0.241) 比 Bottom-5 组 (0.142) 高出 0.099，约 1.15 个标准差。Top-5 组有 21.2% 的句子相似度超过 0.3，而 Bottom-5 组仅有 1.2%，相差 17 倍。这表明 AI 相关语义在国家间确实有系统性的差异。

5 验证：具体例句分析

5.1 Top-10 最接近 AI 概念的句子

表 4 列出相似度最高的 10 条句子。几乎所有句子都直接涉及高科技制造、数字经济、研发投入、半导体、fintech 等与 AI 锚点高度相关的内容。

Table 4: Top-10 AI 相似度例句

#	国家	句子 (截断)
1	China	Manufacturing has been transitioning toward high-tech industries such as electric vehicles, renewable energy, telecommunications...
2	Thailand	Telecommunications and trade in services are emerging as centers of industrial expansion and economic competitiveness.
3	Turkey	First established in 2000, many technoparks were pioneered by Turkish universities, now hosting over 1,600 R&D centers...
4	Brazil	...Brazil managed to create a diversified industrial base, including the adoption of artificial intelligence...
5	South Korea	...economic growth is increasingly concentrated in a small number of tech-related companies...
6	UK	The UK's technology sector has an enterprise value of US\$1.2 trillion, with fintech, health technology, and semiconductors...
7	India	India's digital economy was estimated to be 11.7% of GDP, with its total value expected to surpass US\$1 trillion by 2029.
8	Netherlands	Many of the world's largest tech companies are based in Amsterdam...such as IBM, Microsoft, Google, Oracle, Cisco, Uber, Netflix.
9	India	The government plays a major role in sectors like supercomputing, space and shipping...
10	South Africa	The city is home to hundreds of tech firms, and is referred to as the "Startup Capital of Africa."

5.2 Bottom-5 最远离 AI 概念的句子

作为对照，表 5 列出相似度最低的 5 条句子。它们讨论的是石油卡特尔、财政赤字、税收、货币等传统经济议题，与 AI 锚点的语义几无重叠。

Table 5: Bottom-5 AI 相似度例句

#	国家	句子
1	Saudi Arabia	Saudi Arabia is a founding member of the OPEC cartel.
2	Mexico	Mexico was not significantly affected by the 2002 South American crisis...
3	Netherlands	The stern financial was abandoned in 2009, because of the then-current credit crises.
4	Bangladesh	Tax collection remains very low, with tax revenues accounting for only 7.7% of GDP.
5	Netherlands	In 2016, the state budget showed a surplus of 0.4%.

5.3 按四维度的最高得分例句

为进一步验证 AI 概念向量的四个子维度是否有意义，表 6 展示了各维度得分最高的 3 条句子。

Table 6: 各维度 Top-3 例句

维度	国家	例句（截断）
AI 核心	Brazil	...Brazil created a diversified industrial base, including the adoption of artificial intelligence...
	South Korea	South Korea's economy relies significantly on semiconductor and other AI-related gear exports (40% of exports).
	China	Manufacturing has been transitioning toward high-tech industries such as electric vehicles, renewable energy...
经济转型	China	Manufacturing has been transitioning toward high-tech industries...
	Thailand	Telecommunications and trade in services are emerging as centers of industrial expansion...
	South Korea	...economic growth increasingly concentrated in tech-related companies...
劳动力	China	Manufacturing has been transitioning toward high-tech industries...
	Ethiopia	...job creation has not caught up with the increased number of secondary and postsecondary graduates.
	Thailand	Telecommunications and trade in services are emerging...
基础设施	Thailand	Telecommunications and trade in services are emerging as centers of industrial expansion...
	India	The government plays a major role in sectors like supercomputing, space and shipping...
	Turkey	...technoparks pioneered by Turkish universities, hosting over 1,600 R&D centers...

这些例句定性分析表明，AI 概念向量确实捕捉了与 AI、数字经济和科技转型相关的语义信号，而非无关的噪声。

6 讨论

6.1 关键发现

中国的第一名是合理的。中国最高分句子出自高科技制造转型叙事，且 R&D 投资句也进入 Top-15。这在语义上与锚点中的「automated manufacturing」、「digital transformation」、「R&D investment」直接对应。

新兴经济体在 AI 文本信号上可能强于部分发达国家。Top-5 中南非、印度、印度尼西亚均为发展中国家。这可能不是因为它们实际上技术更强，而是经济描述中更强调转型叙事——从传统到数字化的语义跃迁比成熟发达经济体的「常态」描述更具显著性。

发达国家排名分化。美国 (#6)、英国 (#7) 排名靠前但并非前 5；德国 (#27)、瑞士 (#26) 居后。德国经济描述偏重制造业传统优势（汽车、化工），瑞士偏重金融和制药，AI/数字相关词汇的出现频率确实较低。

6.2 方法评估与局限

1. 四维度锚点设计合理：维度间相关系数 0.52–0.65，既不过高（说明有区分度）也不过低（说明共享高阶语义），合成为单一 AI 概念向量是合理的。
2. **Top/Bottom** 例句提供了定性验证 (**face validity**)：高分句子涉及 AI、半导体、数字经济、tech firms；低分句子涉及 OPEC、预算赤字、税收。语义区分清晰。
3. 语料规模小（30 文档、588 句），不宜过度推断。扩展至更多国家或全词条正文可提高区分度。
4. 仅分析英文 **Wikipedia**，非英语国家可能有不同的信息含量。
5. 均值聚合平权化。首句通常更具总体性，未来可加权（如 tf-idf 或位置权重）。

7 结论

本文用 463 行 Python 代码（3 个脚本），从 Wikipedia 英文经济词条中提取了「AI 依赖度」的跨国文本指标。 workflow 覆盖数据抓取、预处理、词向量编码、相似度计算、国家聚合、定量报告和 LaTeX 排版的全链条，适合作为 text-as-data 课堂演示。

主要发现：中国（0.258）、南非（0.247）、印度（0.237）排名最高；沙特阿拉伯（0.105）垫底。Top-5 组的高相似度句子占比是 Bottom-5 组的 17 倍。四维度分析与例句验证均显示指标具有良好的表面效度。

数据可用性声明：原始 Wikipedia 语料存放在 `data/raw/text_corpus/`，预处理输出在 `data/processed/text_corpus/`，三个 Python 脚本在 `scripts/` 目录下 (`preprocess_text_corpus.py`、`ai_dependency_keyword.py`、`ai_dependency_embedding.py`)，均可复现。本报告对应 PDF 由 xelatex 三次编译生成。